Projet Big Data
Analyse tabulaire / séries temporelles avec Python

Lorenzini Thomas Baptiste DIDIER Antoine DUARTE

Avril 2026

Table des matières

1 Description du projet **2**

2 Objectifs **2**

3 Jeu de données et chargement **2**
3.1 Source du jeu de données 2
3.2 Pourquoi ce jeu de données 2
3.3 Nature des données 2
3.4 Chargement 2

4 Prétraitement **2**
4.1 Qualité initiale 2
4.2 Techniques appliquées 3

5 EDA et visualisations **3**
5.1 Statistiques sommaires 3
5.2 Graphiques réalisés 3

6 Valeurs aberrantes et anomalies **3**
6.1 Outliers (IQR) 3
6.2 Anomalies statistiques (Z-score, bonus) 3

7 Manipulation des données **4**
7.1 Grouping et agrégation 4
7.2 Filtrage et tri 4
7.3 Analyse temporelle (bonus) 5

8 Interprétation et conclusions **5**

1 Description du projet

Ce projet vise à exploiter des données industrielles massives afin d'en extraire des informations utiles à la prise de décision. Le jeu de données principal est `extrusion.csv` (série temporelle), accompagné de `stat.csv` (statistiques de variables).

2 Objectifs

Les objectifs couverts sont :
— exploration des données (structure, motifs, anomalies),
— prétraitement (valeurs manquantes, types, dédoublonnage),
— visualisation (linéaire, dispersion, barres, heatmap, KDE),
— interprétation des résultats et dérivation d'informations.

3 Jeu de données et chargement

3.1 Source du jeu de données

Le jeu de données exploité est le fichier `extrusion.csv` fourni dans le cadre du projet (données de ligne d'extrusion), complété par `stat.csv` pour le choix des variables.

3.2 Pourquoi ce jeu de données

Ce jeu de données a été retenu pour trois raisons principales :
— il s'agit d'une vraie série temporelle industrielle, donc pertinente pour un projet big data appliqué ;
— le volume est important (grand nombre d'observations et nombreuses variables capteurs), ce qui permet de pratiquer des techniques de prétraitement réalistes ;
— le contexte de ligne d'extrusion est propice à la détection d'anomalies et à l'analyse des relations entre mesures (pression, débit, épaisseur), en lien direct avec les objectifs du projet.

3.3 Nature des données

Le fichier `extrusion.csv` contient des mesures temporelles industrielles (pression, débit, épaisseur, etc.).

Le volume élevé de données (plus de 226000 observations) justifie l'utilisation d'outils adaptés comme Pandas et de techniques de réduction de complexité (sélection de variables pertinentes, agrégations ciblées et lissages temporels) pour conserver des temps de traitement raisonnables.

3.4 Chargement

Le chargement a été réalisé avec `pandas.read_csv()` en sélectionnant un sous-ensemble de variables pertinentes (forte variance + variables métier), pour conserver une analyse lisible et robuste.

Le sous-ensemble de variables est un compromis entre :
— représentativité du procédé,
— lisibilité des analyses et visualisations,
— coût de calcul raisonnable sur machine étudiante.

4 Prétraitement

4.1 Qualité initiale

Résultats mesurés sur l'échantillon de travail :
— dimensions initiales : **226536 lignes x 15 colonnes**,

— valeurs manquantes avant traitement : **1845**,
— doublons avant traitement : **0**.

4.2 Techniques appliquées

— Conversion de types : conversion numérique explicite des colonnes de mesures.
— Valeurs manquantes : imputation par **médiane**.
— Justification de l'imputation médiane : plus robuste que la moyenne face aux valeurs extrêmes (outliers) fréquentes en données industrielles.
— Doublons : vérification puis suppression via `drop_duplicates()`.
— Valeurs incohérentes : conversion avec `errors='coerce'` pour transformer les entrées non numériques en `NaN`, puis traitement par imputation médiane.
— Feature engineering : création de `pressure_diff`, `pressure_roll_mean_30` et `hour`.

Après traitement :
— valeurs manquantes : **0**,
— doublons : **0**,
— dimensions finales après prétraitement : **226536 lignes x 18 colonnes**.

5 EDA et visualisations

5.1 Statistiques sommaires

Les statistiques descriptives ont été calculées avec `df.describe()` directement dans le notebook. Ces statistiques permettent d'identifier rapidement :
— les plages de variation,
— les écarts de dispersion entre variables,
— les premières incohérences potentielles avant modélisation.

5.2 Graphiques réalisés

— linéaire (tendance temporelle),
— dispersion (débit vs pression),
— barres (pression moyenne par heure),
— heatmap de corrélation,
— histogramme + KDE,
— boxplot,
— visualisation interactive Plotly (bonus).

Les figures sont produites et interprétées dans le notebook. Pour améliorer la lisibilité du livrable PDF, trois visualisations clés sont intégrées ci-dessous.

6 Valeurs aberrantes et anomalies

6.1 Outliers (IQR)

Le nombre de valeurs aberrantes détectées sur la pression par la méthode IQR est de **29865**. Ce volume élevé peut refléter des régimes de production différents et non uniquement des erreurs.

Décision appliquée : les outliers n'ont pas été supprimés automatiquement, car ils peuvent correspondre à des états réels du procédé (arrêts, redémarrages, transitions).

6.2 Anomalies statistiques (Z-score, bonus)

Le nombre d'anomalies détectées avec la règle $|z| > 3$ sur la pression est faible, ce qui suggère surtout des changements de régime plutôt que des erreurs massives.

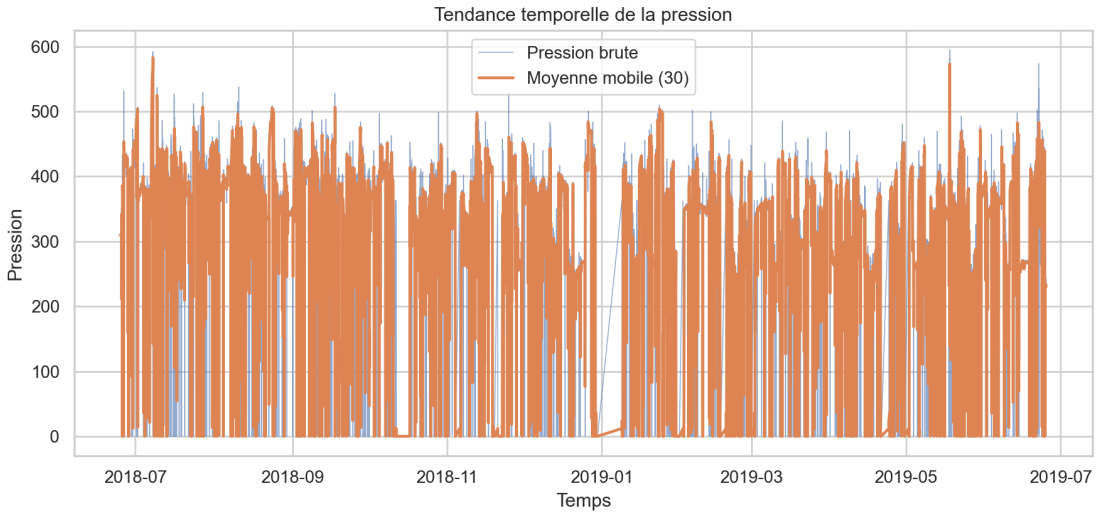

FIGURE 1 – Tendance temporelle de la pression avec moyenne mobile (30 points).

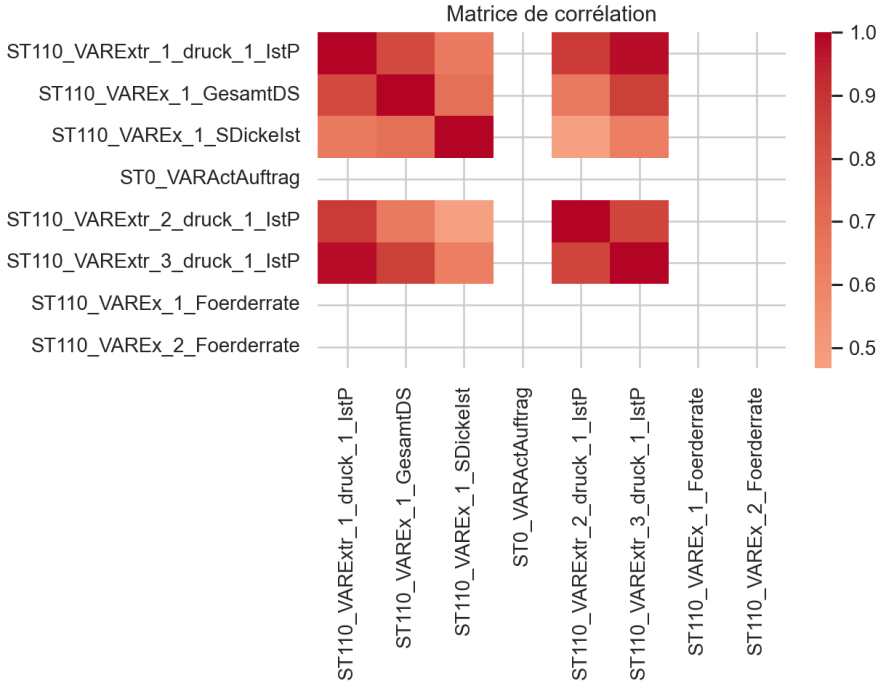

FIGURE 2 – Matrice de corrélation entre les principales variables numériques.

7 Manipulation des données

7.1 Grouping et agrégation

Les heures présentant les pressions moyennes les plus élevées sont : 20h, 19h, 13h, 21h et 12h.

7.2 Filtrage et tri

Les 5% plus fortes pressions ont été extraites puis triées, avec des maxima observés autour de 595.

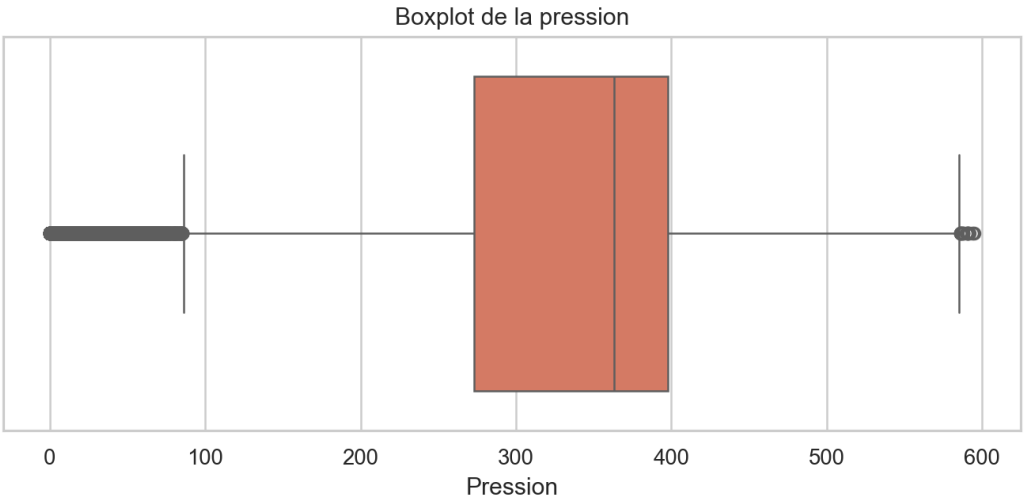

FIGURE 3 – Boxplot de la pression pour visualiser la dispersion et les valeurs aberrantes.

7.3 Analyse temporelle (bonus)

La moyenne mobile sur 30 pas de temps a été appliquée pour lisser le bruit et faire ressortir les tendances globales.

En complément, l'analyse par heure met en évidence une périodicité journalière (variations récurrentes de la pression selon les heures de la journée), ce qui constitue un signal de saisonnalité intra-journalière.

8 Interprétation et conclusions

- Le pipeline de prétraitement assure une base propre (0 valeurs manquantes restantes) pour l'analyse.
- Les corrélations positives entre pression et débit suggèrent des interactions fortes des variables de process.
- Les variations horaires indiquent des plages opérationnelles plus chargées, exploitables pour le pilotage qualité.
- Le grand nombre d'outliers IQR invite à distinguer les régimes opérationnels des erreurs de capteurs.

En synthèse, le jeu de données choisi est pertinent pour illustrer un cycle complet de science des données : acquisition, nettoyage, exploration, extraction d'informations et interprétation métier. Les résultats obtenus montrent qu'une approche méthodique permet déjà de dégager des indicateurs exploitables pour le suivi de production et la qualité. Ces résultats pourraient être utilisés dans un cadre industriel réel pour anticiper des dérives du procédé ou améliorer le contrôle qualité.

Limites et perspectives

Cette étude présente néanmoins certaines limites : bruit de mesure, capteurs potentiellement imparfaits, et absence d'informations contextuelles détaillées (maintenance, changements d'outillage, consignes opérateur) qui aideraient à mieux expliquer certaines anomalies. Une suite naturelle serait d'enrichir les données avec ces variables de contexte et de comparer plusieurs méthodes de détection d'anomalies.